

# Clasificación Automática de Calidad de Frutas mediante Visión por Computadora: un Estudio Comparativo entre Modelos Tradicionales y una Red Convolutacional

Heiner Danit Rincón Carrillo  
A00402510

Ruben Dario Marquinez Rincón  
A00401286

Simon Reyes Riveros  
A00400880

Juan David Ocampo Martinez  
A00401856  
*Ingeniería de Sistemas, Universidad ICESI*  
*Cali, Colombia*  
Algoritmos y Programación III — 2026-1

---

### A. Resumen (Abstract)

La clasificación manual de la calidad de frutas es lenta, subjetiva y propensa a errores, lo que genera pérdidas económicas y desperdicio de alimentos. En este trabajo desarrollamos un sistema de visión por computadora capaz de clasificar la calidad de una fruta individual en tres categorías (mala, regular, buena) y estimar su tamaño relativo. Trabajando sobre un conjunto de 9.515 imágenes (6 frutas  $\times$  3 niveles de calidad), seguimos la metodología CRISP-DM y comparamos dos modelos de aprendizaje tradicional (Random Forest y SVM con kernel RBF) usando características de color (HSV) y forma (HOG), junto con una red neuronal convolucional (CNN) pequeña entrenada desde cero, todo frente a una línea base. El mejor modelo, SVM-RBF, alcanzó un **Macro-F1 de 0,957** en prueba. También detectamos y cuantificamos una posible fuga de datos por casi-duplicados (fotos en ráfaga) mediante *hashing* perceptual; al re-evaluar con una partición consciente de grupos confirmamos que el desempeño **no es inflado** (incluso mejoró levemente), lo que nos indica que la generalización es real. Finalmente, desplegamos el sistema en una interfaz Streamlit.

**Palabras clave:** visión por computadora, clasificación de calidad, SVM, CNN, HOG, CRISP-DM, fuga de datos.

### B. I. Introducción

En mercados, centrales de abasto y agroindustrias, la inspección de productos frescos todavía se realiza en su mayor parte de forma manual. Este proceso es **subjetivo** (criterios distintos entre operarios), **lento** y **costoso**, y sus errores provocan que producto bueno se descarte o que producto en mal estado llegue al consumidor, con el consiguiente impacto económico y de desperdicio de alimentos.

El objetivo principal de este proyecto fue **automatizar la clasificación de calidad** de una fruta individual a partir de una fotografía sobre fondo simple, como apoyo a la decisión humana y no como reemplazo de ella. Las salidas del sistema son: (i) la **clase de calidad**  $\in \{\text{Bad, Regular, Good}\}$  y (ii) una **estimación de tamaño** (pequeño/mediano/grande). La motivación es reducir pérdidas económicas y estandarizar un criterio que hoy varía de operario a operario, manteniendo bajos requerimientos de hardware para que pueda adoptarse fácilmente.

Consideramos que la contribución más importante no es solo el clasificador en sí, sino una **evaluación metodológicamente honesta**: identificamos un sesgo de procedencia en los datos y una posible fuga por casi-duplicados, y verificamos empíricamente que el alto desempeño obtenido refleja generalización real y no un artefacto del proceso de partición.

### C. II. Fundamentos Teóricos

**Características de imagen.** El espacio **HSV** separa el matiz (color/madurez) de la iluminación, siendo más robusto que RGB para juzgar calidad [Ref. visión]. El descriptor **HOG** (Histogram of Oriented Gradients) [Dalal2005] resume la forma y los bordes locales mediante histogramas de gradientes orientados, útil para detectar defectos y deformaciones.

**Modelos.** La **máquina de soporte vectorial (SVM)** [Cortes1995] busca el hiperplano de máximo margen; con kernel RBF,  $K(x, x') = \exp(-\gamma \|x - x'\|^2)$ , separa clases no linealmente. El **Random Forest** [Breiman2001] promedia árboles de decisión entrenados sobre subconjuntos, reduciendo varianza. Las **CNN** [LeCun1998] aprenden jerarquías de características directamente de los píxeles mediante convoluciones y *pooling*.

**Métricas.** Ante desbalanceo, la *accuracy* es engañosa; se usa el **Macro-F1**, promedio no ponderado del F1 por clase, que penaliza ignorar las minoritarias.

**Segmentación.** El método de **Otsu** [Otsu1979] selecciona el umbral que maximiza la varianza entre clases (fondo/objeto), adecuado para fondos uniformes.

### D. III. Metodología (CRISP-DM aplicado)

Para este proyecto seguimos las seis fases de CRISP-DM [Wirth2000], adaptándolas a nuestro problema de clasificación de frutas. La Fig. 1 muestra el diagrama de flujo personalizado.




Fig. 1. Diagrama CRISP-DM adaptado al proyecto de clasificación de calidad de frutas.

**1) Comprensión del negocio.** Definimos las 3 clases de calidad y el tamaño relativo como salidas del sistema, y elegimos el **Macro-F1** como métrica principal. También decidimos vigilar especialmente el *recall* de Bad por ser el error más costoso (clasificar mala como buena).

**2) Comprensión de los datos.** El conjunto cuenta con 9.515 imágenes (JPEG/PNG) de 6 frutas (Apple, Banana, Guava, Lime, Orange, Pomegranate)  $\times$  3 calidades. Al explorar los datos encontramos varias cosas interesantes: desbalanceo moderado (Regular 4.612 vs Bad 2.244), resoluciones muy heterogéneas (desde 13 px hasta 4.032 px), mezcla de imágenes RGB y RGBA, y un **sesgo de procedencia** que nos llamó mucho la atención: las imágenes diminutas y el canal alfa estaban

correlacionados con la clase (0 diminutas en Good; 100 % de las RGBA en Regular).




Fig. 1. Distribución de imágenes por clase de calidad.

3) **Preparación de los datos.** Descartamos las imágenes diminutas (<64 px), quedando **7.803**; aplanamos RGBA→RGB para eliminar el atajo del canal alfa, redimensionamos a 128×128 y normalizamos a [0,1]. Usamos una partición **70/15/15** estratificada por fruta×calidad (train 5.461 / val 1.171 / test 1.171), con semilla fija para reproducibilidad. El desbalanceo lo manejamos con **pesos de clase** (Bad 1,47; Good 0,98; Regular 0,77) y *augmentation* ligera. Para los modelos tradicionales extrajimos características: **histograma HSV** (96 dims) + **HOG** (1.764 dims) = 1.860 dims.

4) **Modelado.** Entrenamos una línea base (clase mayoritaria), **Random Forest** y **SVM-RBF** (con GridSearchCV, CV=3, métrica f1\_macro), y una **CNN pequeña desde cero** (3 bloques Conv-BN-ReLU-MaxPool de 32/64/128 filtros + cabeza densa; Adam, EarlyStopping).




Fig. 2. Curvas de entrenamiento de la CNN (pérdida y accuracy).

5) **Evaluación.** Calculamos métricas en test, construimos matrices de confusión, analizamos los errores más frecuentes e investigamos la posible fuga de datos por casi-duplicados.

6) **Despliegue.** Interfaz **Streamlit** que permite cargar o capturar una imagen, predice la calidad con SVM o CNN y estima el tamaño usando segmentación por Otsu más terciles de área por fruta.




Fig. 3. Demostración del pipeline: segmentación, calidad y tamaño.

### E. IV. Resultados

Los tres modelos superaron ampliamente la línea base, lo que confirma que el problema tiene una señal aprendible. La Tabla I resume el desempeño en el conjunto de **prueba**.

TABLA I — Desempeño en prueba (test)

| Modelo             | Macro-F1 | Balanced acc. | Recall Bad |
|--------------------|----------|---------------|------------|
| Baseline (mayoría) | 0,201    | 0,333         | 0,000      |
| CNN (desde cero)   | 0,935    | 0,932         | 0,857      |
| Random Forest      | 0,941    | 0,929         | 0,801      |
| SVM (RBF)          | 0,957    | 0,954         | 0,902      |

Los mejores hiperparámetros encontrados por GridSearch fueron: SVM C=10,  $\gamma$ =scale; RF n\_estimators=400, max\_depth=None. La CNN convergió en 24 épocas, lo que tomó aproximadamente 12 minutos en CPU. El **SVM-RBF** fue el mejor en Macro-F1 y en *recall* de Bad.



Fig. 4. Matrices de confusión en prueba (RF, SVM, CNN).

**Análisis de errores.** Bad es la clase más difícil y Good la más fácil (F1≈0,98). El error más costoso (Bad→Good) ocurrió

solo **2 veces** en 266 frutas malas; las confusiones predominantes son entre clases adyacentes.

**Investigación de fuga de datos.** Usando *difference hash* de 256 bits y componentes conexas (Hamming  $\leq 10$ ) se detectó que el **11,8 %** de las imágenes son casi-duplicados y que el **15 %** del test tiene un casi-duplicado en train. Al reentrenar con una partición **consciente de grupos** (cada ejemplar íntegro en una sola partición), el desempeño **no disminuye** (Tabla II).

**TABLA II — Macro-F1 con/sin fuga**

| Modelo        | Split aleatorio | Split por grupos (sin fuga) |
|---------------|-----------------|-----------------------------|
| Random Forest | 0,941           | 0,946                       |
| SVM (RBF)     | 0,957           | 0,964                       |
| CNN           | 0,935           | 0,946                       |




Fig. 5. Impacto de la fuga: Macro-F1 con split aleatorio vs. por grupos.

## F. V. Análisis de Resultados

**Generalización y sobreajuste.** Al comparar validación (0,955) con prueba (0,957) para el SVM, pudimos confirmar **ausencia de sobreajuste severo**; en la CNN, las curvas train/val convergen sin divergencia. Es notable que la partición sin fuga **no degrada** —e incluso mejoró levemente— el desempeño en los tres modelos: esto nos permite **descartar** la hipótesis de que las métricas estuvieran infladas por memorización de casi-duplicados, y nos confirma que los modelos generalizan bien a ejemplares nuevos.

**Qué funciona y qué falla.** Para este dominio específico (fruta centrada, fondo simple), encontramos que las **características clásicas** (HSV+HOG) con un SVM **igualan o superan** a una CNN pequeña entrenada desde cero, con mucho menor costo de cómputo; esto sugiere que la señal de calidad reside fuertemente en color y textura de bordes, bien capturados por HOG y HSV. La CNN, sin transfer learning y con datos limitados por clase minoritaria, rinde algo menos pero trabaja directamente sobre la imagen. El punto débil común es la clase Bad, cuyos defectos son sutiles y heterogéneos.

**Comparación con la literatura.** Al revisar la literatura, encontramos que trabajos de *Fruit Quality Classification* reportan exactitudes altas (>90 %) con CNN y transfer learning; nuestros resultados son consistentes en magnitud, aunque nosotros priorizamos entrenar una CNN desde cero y decidimos

añadir una **auditoría de fuga** poco frecuente en la literatura básica, que matiza la interpretación de métricas altas.

**Consideraciones éticas y de impacto.** Desde el inicio concebimos el sistema como **apoyo** a la decisión (muestra probabilidades, no veredictos absolutos); mitigamos el sesgo de procedencia que detectamos y reportamos honestamente las limitaciones del sistema. El balance de impactos (social, económico, ambiental, global) nos parece positivo, con riesgos que consideramos gestionables (transición laboral, mantenimiento del modelo, generalización a otras especies).

## G. VI. Conclusiones y Trabajo Futuro

En este proyecto construimos un sistema completo de clasificación de calidad de frutas siguiendo CRISP-DM, donde comparamos modelos tradicionales con una CNN. El **SVM-RBF** sobre características HSV+HOG fue el mejor (Macro-F1 0,957 en prueba; 0,964 sin fuga), con un *recall* de Bad de 0,90 y apenas 2 errores del tipo más costoso. La auditoría de fuga por casi-duplicados confirmó que el desempeño es **real**. Finalmente, desplegamos el sistema en una interfaz que cualquiera puede usar.

**Trabajo futuro:** (i) *transfer learning* con congelamiento de capas para potenciar la CNN; (ii) ampliar la recolección de datos a más especies y regiones; (iii) mejorar la estimación de tamaño con referencia de escala física; (iv) implementar monitoreo de deriva de datos en producción; (v) añadir explicabilidad mediante mapas de saliencia para que el usuario entienda en qué se fija el modelo.

## H. Referencias

- [Wirth2000] R. Wirth and J. Hipp, "CRISP-DM: Towards a standard process model for data mining," in *Proc. 4th Int. Conf. Practical Application of Knowledge Discovery and Data Mining*, 2000, pp. 29–39.
- [Dalal2005] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," in *Proc. IEEE CVPR*, 2005, pp. 886–893.
- [Cortes1995] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [Breiman2001] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [LeCun1998] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proc. IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [Otsu1979] N. Otsu, "A threshold selection method from gray-level histograms," *IEEE Trans. Syst., Man, Cybern.*, vol. 9, no. 1, pp. 62–66, 1979.
- [Pedregosa2011] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [Abadi2016] M. Abadi et al., "TensorFlow: A system for large-scale machine learning," in *Proc. 12th USENIX OSDI*, 2016, pp. 265–283.

[Streamlit] Streamlit Inc., "Streamlit: A faster way to build and share data apps," [En línea]. Disponible: <https://streamlit.io>

[Kaggle] R. Park, "Fruit Quality Classification," Kaggle Dataset. [En línea]. Disponible en: <https://www.kaggle.com/datasets/ryandpark/fruit-quality-classification>. [Accedido: 2026].

[Repo] H. Rincón, R. Marquínez, S. Reyes y J. Ocampo, "Clasificación Automática de Calidad de Frutas por Visión por Computadora," Repositorio GitHub. [En línea]. Disponible en: [https://github.com/Heiner1905/APOIII\\_FINAL](https://github.com/Heiner1905/APOIII_FINAL). [Accedido: 2026].

[Video] H. Rincón, R. Marquínez, S. Reyes y J. Ocampo, "Video demostración del proyecto — Clasificación de calidad de frutas," 2026. [En línea]. Disponible en: [https://drive.google.com/drive/folders/1K9\\_jht2DWNGJL3BbdwsTF-9S0b6-QU2I?usp=sharing](https://drive.google.com/drive/folders/1K9_jht2DWNGJL3BbdwsTF-9S0b6-QU2I?usp=sharing)